

Preproceso: mejora de la imagen

Gonzalez & Woods Digital Image Processing cap4

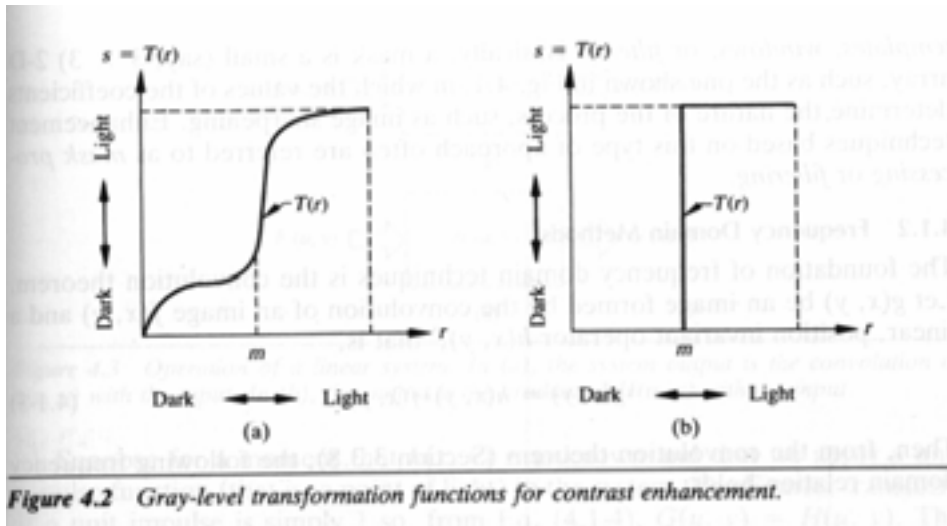
- Transformaciones de la imagen dirigidas a mejorarla para el proceso posterior
 - Mejora de contraste:
 - Operaciones puntuales de transformación
 - Operaciones basadas en el histograma: ecualización
 - Binarización
 - Suavización y afilado
 - filtros lineales
 - filtros no lineales
 - Pseudocoloreado
 - Otras: separación de planos de bits....

Operaciones puntuales de transformación de la intensidad

$$g(x, y) = T[f(x, y)]$$

$$s = T(r)$$

Son transformaciones de la imagen que no involucran vecindarios (mascaras de convolución)



Estiramiento de contraste, en el limite es la binarización de la imagen





Imagen inversa

Mejora de la imagen



(a)



(b)



(c)



(d)

Estiramiento de contraste mediante una función lineal por trozos especificada por dos puntos.

En el limite, cuando $r_1=r_2$ se convierte en un proceso de binarización por un umbral

Compresión del rango de valores de intensidad, sirve para visualizar algunas funciones, como el espectro de las transformadas.

$$s = c \log(1 + |r|)$$





Figure 4.6 Compression of dynamic range: (a) logarithm transformation function; (b) image with large dynamic range (pixel values ranging from 0 to 2.5×10^6); (c) result after transformation.




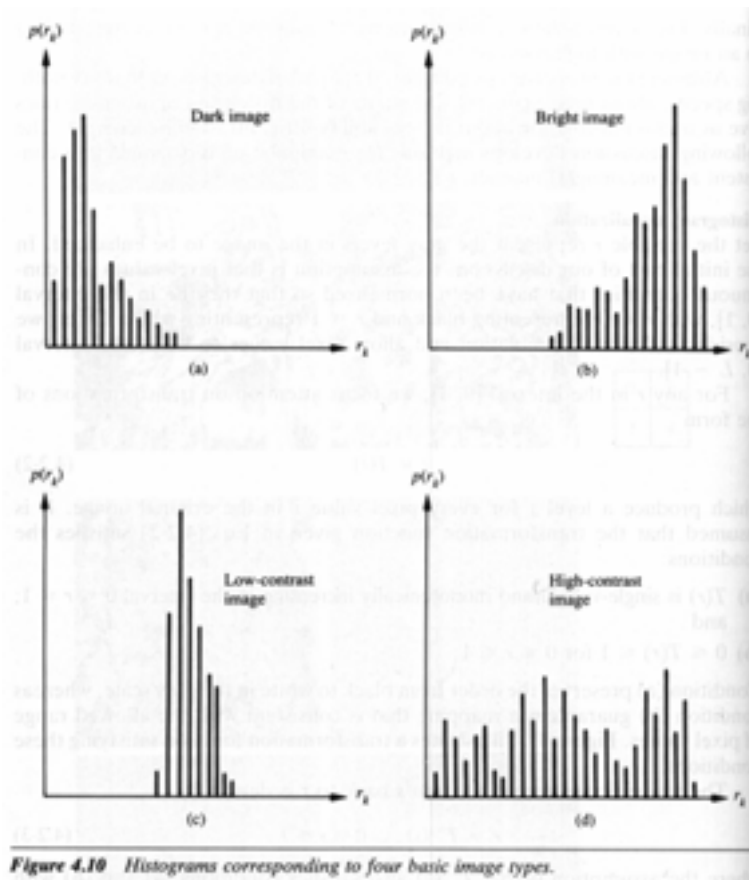
Figure 4.7 Intensity-level slicing: (a) a transformation function that highlights a range $[A, B]$ of intensities while diminishing all others to a constant, low level; (b) a transformation that highlights a range $[A, B]$ of intensities but preserves all others; (c) an image; (d) result of using the transformation in (a).

Gray level slicing: resaltar un rango de valores de intensidad que corresponden con objetos de interés.

Se requiere el conocimiento a priori de los rangos de valores apropiados.

Histograma de la imagen: estimación de la distribución de probabilidad de los niveles de intensidad

$$p(r_k) = n_k/n, \quad k = 0, 1, 2, \dots, L - 1.$$



Algunos ejemplos de distribuciones típicas de los niveles de gris.

Las transformaciones de intensidad pueden entenderse como transformaciones entre variables aleatorias que siguen ddp determinadas por la transformación

$r = 0$ black $s = T(r)$ transformations
 $r = 1$ white.

(a) $T(r)$ is single-valued and monotonically increasing in the interval $0 \leq r \leq 1$;

(b) $0 \leq T(r) \leq 1$ for $0 \leq r \leq 1$.

inverse transformation $r = T^{-1}(s)$ $0 \leq s \leq 1$

probability density functions $p_r(r)$ $p_s(s)$

$$p_s(s) = \left[p_r(r) \frac{dr}{ds} \right]_{r=T^{-1}(s)}$$




Figure 4.11 A gray-level transformation function.

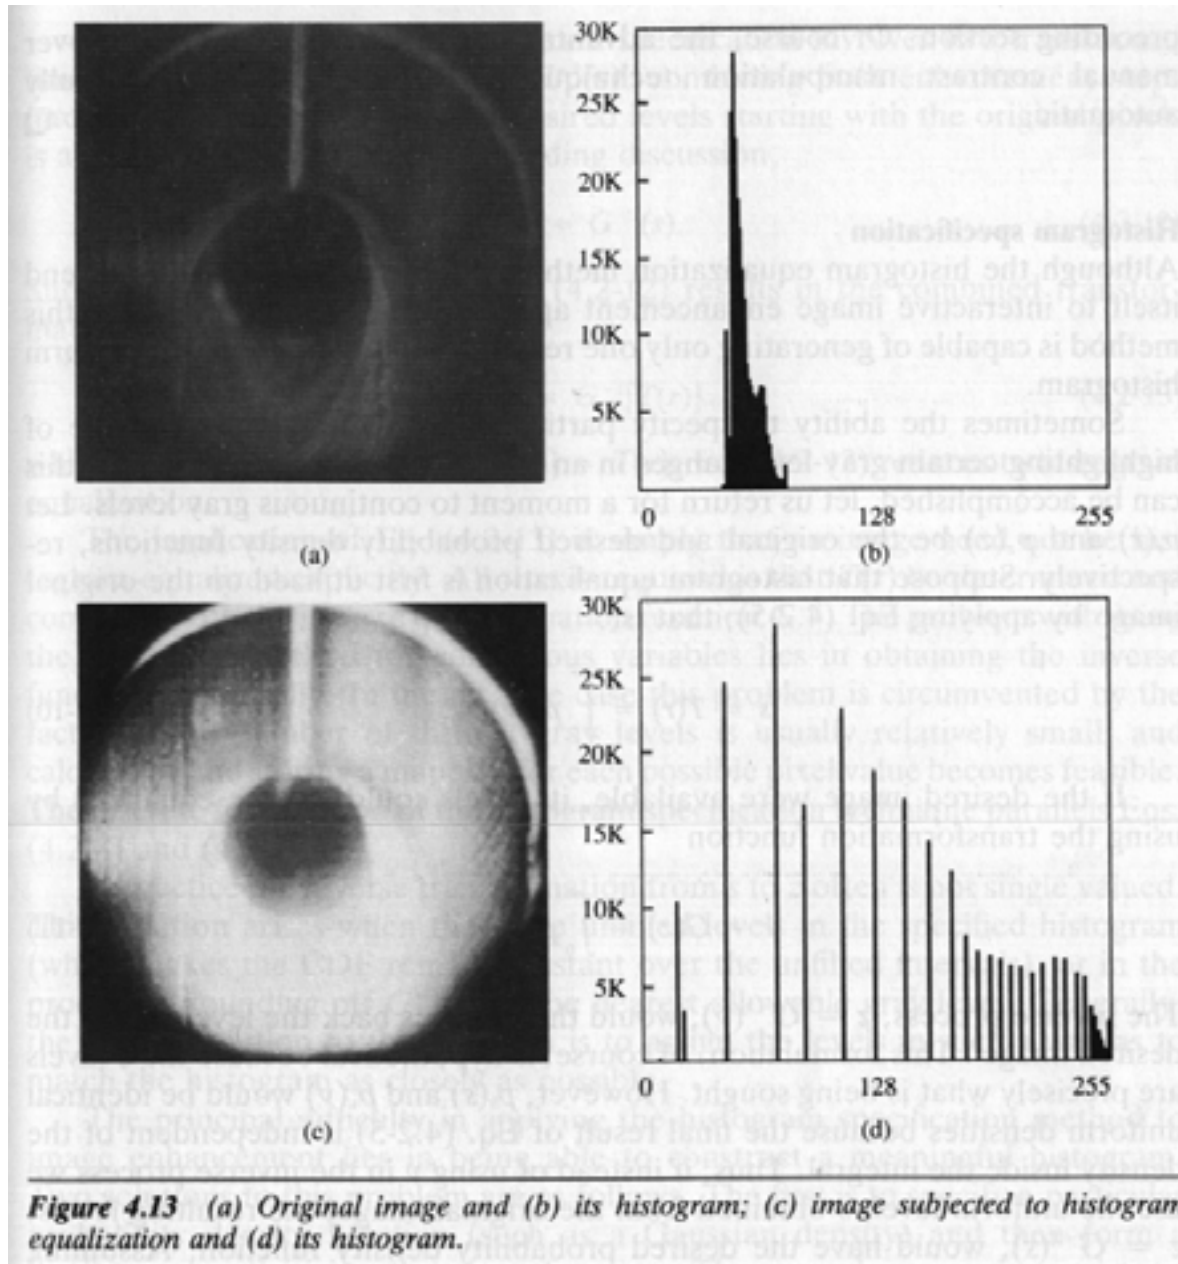
La ecualización de la imagen consiste en tratar de transformar el histograma de la imagen en un histograma uniforme. Se consigue utilizando como función de transformación la distribución acumulativa de la intensidad.

$$\begin{aligned}
 s &= T(r) = \int_0^r p_r(w)dw \quad 0 \leq r \leq 1 \\
 \frac{ds}{dr} &= p_r(r). \\
 p_s(s) &= \left[p_r(r) \frac{1}{p_r(r)} \right]_{r=T^{-1}(s)} \\
 &= [1]_{r=T^{-1}(s)} \\
 &= 1 \quad 0 \leq s \leq 1
 \end{aligned}$$

Formulación continua

$$\begin{aligned}
 p_r(r_k) &= \frac{n_k}{n} \quad 0 \leq r_k \leq 1 \quad \text{and} \quad k = 0, 1, \dots, L-1 \\
 s_k &= T(r_k) = \sum_{j=0}^k \frac{n_j}{n} \\
 &= \sum_{j=0}^k p_r(r_j) \quad 0 \leq r_k \leq 1 \quad \text{and} \quad k = 0, 1, \dots, L-1. \\
 r_k &= T^{-1}(s_k) \quad 0 \leq s_k \leq 1
 \end{aligned}$$

Formulación discreta



Ejemplo de ecualización del histograma. El histograma resultante no es perfectamente uniforme debido a los efectos de la discretización.

Especificación del histograma: se conoce un histograma deseado para la imagen.

$$s = T(r) = \int_0^r p_r(w)dw.$$

Ecualización de la imagen original

$$v = G(z) = \int_0^z p_z(w)dw.$$

Ecualización de la imagen objetivo

$$z = G^{-1}(v)$$

Recuperación de la imagen con el histograma deseado desde una imagen ecualizada.

$$z = G^{-1}[T(r)]$$

Obtención de la imagen con el histograma deseado




Figure 4.14 Illustration of the histogram specification method: (a) original image; (b) image after histogram equalization; (c) image enhanced by histogram specification; (d) histograms.




Figure 4.15 (a) Original image; (b) result of global histogram equalization; (c) result of local histogram equalization using a 7×7 neighborhood about each pixel. (From Fu, Gonzalez, and Lee [1987].)

La ecualización local se realiza por bloques de la imagen que se ecualizan de forma independiente. Permite revelar estructuras finas de la imagen en algunas situaciones.

Procesado local basado en características estadísticas locales: media y varianza. Toma la forma de una amplificación selectiva que depende de la desviación standard local.

$$g(x, y) = A(x, y) \cdot [f(x, y) - m(x, y)] + m(x, y)$$

$$A(x, y) = k \frac{M}{\sigma(x, y)} \quad 0 < k < 1.$$


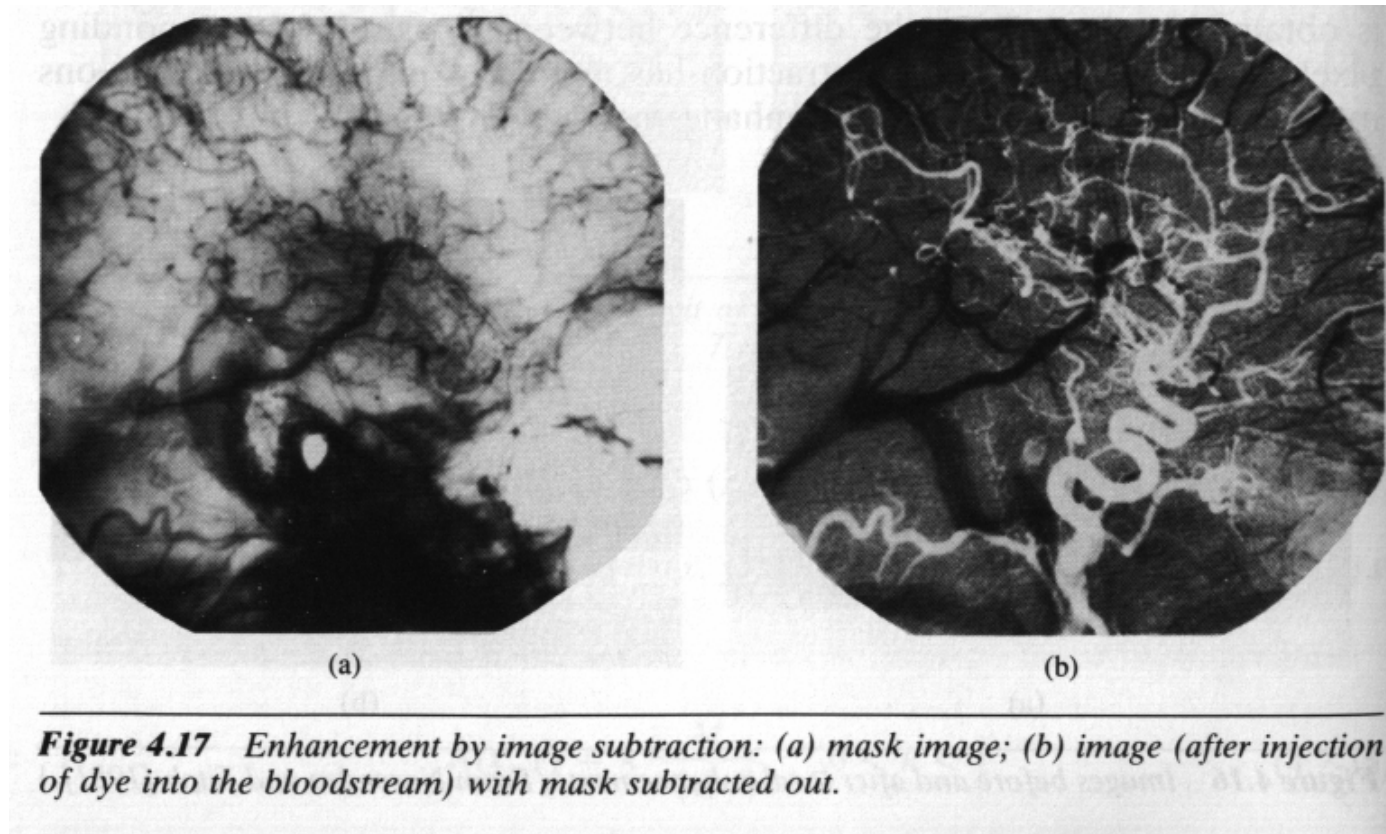



Figure 4.16 Images before and after local enhancement. (From Narendra and Fitch [1981].)

Mejora de la imagen mediante la substracción de una imagen de referencia o máscara.

$$g(x, y) = f(x, y) - h(x, y)$$



Cuando la imagen esta corrompida por ruido gaussiano de media zero, es posible eliminar el ruido mediante el promediado de imágenes corrompidas. Es preciso un alineamiento (registro) cuidadoso de las imágenes para evitar movimientos.



$$g(x, y) = f(x, y) + \eta(x, y)$$

$$\bar{g}(x, y) = \frac{1}{M} \sum_{i=1}^M g_i(x, y)$$

$$E\{\bar{g}(x, y)\} = f(x, y)$$

$$\sigma_{\bar{g}(x, y)}^2 = \frac{1}{M} \sigma_{\eta(x, y)}^2$$

$$\sigma_{\bar{g}(x, y)} = \frac{1}{\sqrt{M}} \sigma_{\eta(x, y)}$$







Figure 4.18 Example of noise reduction by averaging: (a) a typical noisy image; (b)–(f) results of averaging 2, 8, 16, 32, and 128 noisy images.



La descomposición en planos de bits consiste en representar por separado los bits de cada pixel, formando imágenes binarias. Produce algunos efecto exóticos.



Efecto de la operación puntual en el histograma de la imagen,
extraído de Digital Image Processing, Castleman




Figure 6-3 Effect of a point operation on the histogram

Transformación lineal, cuadrática y sigmoide




Figure 6-4 Effect of a linear point operation on a Gaussian histogram




Figure 6-5 A square-law point operation




Figure 6-6 Output histogram from square-law point operation




Figure 6-7 Sine stretch example: (a) transformation; (b) input histogram; (c) inverse transformation; (d) output histogram

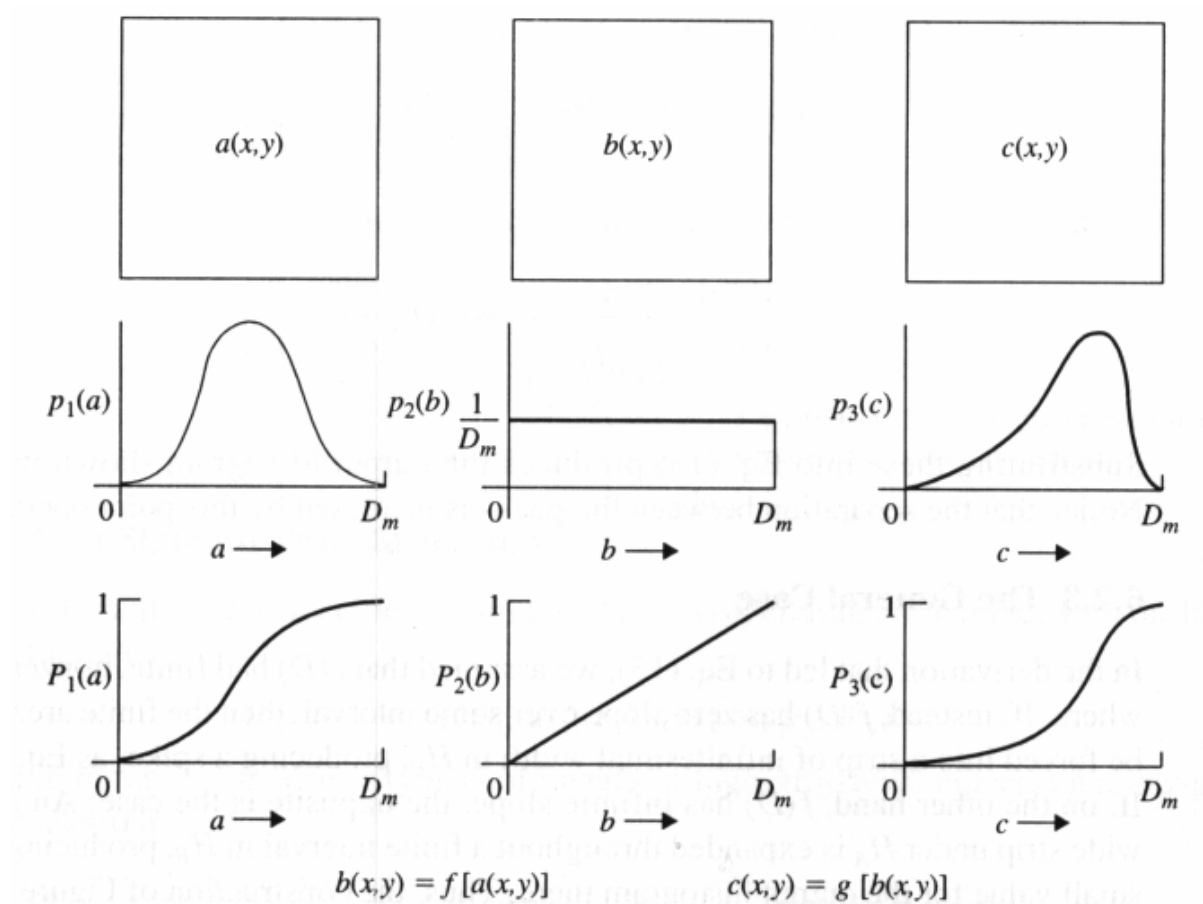


Figure 6-8 Histogram equalization and histogram matching

Binarización (Thresholding)

$$T = T[x, y, p(x, y), f(x, y)]$$

$$g(x, y) = \begin{cases} 1 & \text{if } f(x, y) > T \\ 0 & \text{if } f(x, y) \leq T. \end{cases}$$

La binarización consiste en un Test de los niveles de gris frente a un umbral T , que puede ser global o local.

Desde el punto de vista de visión por computador, la binarización tiene sentido cuando es posible distinguir entre objetos y fondo (background) en base al umbral de los niveles de gris.

El problema de la iluminación: la iluminación no constante perturba el histograma y puede hacer que los objetos detectables mediante binarización dejen de serlo.

$$f(x, y) = i(x, y) r(x, y)$$

$$z(x, y) = \ln f(x, y) = \ln i(x, y) + \ln r(x, y) = i'(x, y) + r'(x, y).$$


La ddp de $z(x, y)$ es convolución de las de $i'(x, y)$ y $r'(x, y)$, por lo que una iluminación no constante destruye las propiedades del histograma como la separación objeto-fondo.

Imagen de un fondo de reflectancia constante, con el campo de iluminación


$$g(x, y) = ki(x, y),$$

La imagen sometida al campo de iluminación no uniforme se puede preprocesar dividiéndola por la imagen de la iluminación. El resultado es una imagen corregida proporcional a la reflectancia:


$$h(x, y) = f(x, y)/g(x, y) = r(x, y)/k.$$



Mapa de reflectancia original sintetizado, binarizable



Campo de iluminación y su efecto en la imagen simulado mediante el producto



Histograma de la imagen sometida al campo de iluminación, se ha perdido la binarización.

Ejemplo de binarización con umbral global




Imagen original y su histograma




Imagen binarizada
(desaparece la sombra)




Figure 2.3 Image of a metal part.

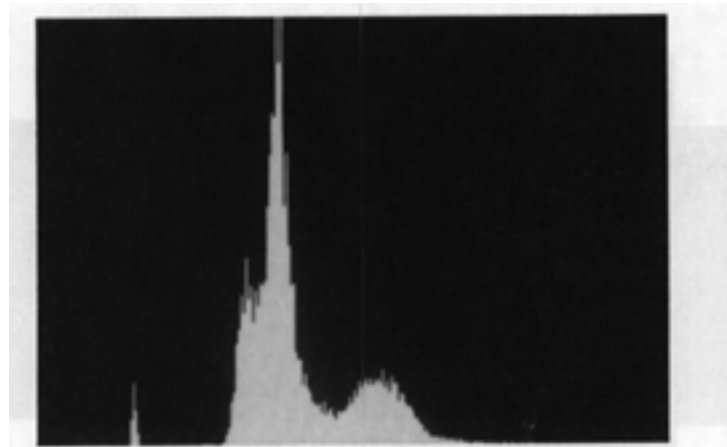


Figure 2.4 Histogram of the image of Fig. 2.3. The histogram shows two dominant modes. The small mode on the left tail is not significant.




Figure 2.5 Metal-part image of Fig. 2.3 thresholded at gray level 148, which is in the valley between the two dominant modes.

La existencia de un valle en el histograma no es indicativo seguro de que se puede discriminar fondo y objeto.




Figure 2.6 BNC T-connector against a dark background.




Figure 2.7 Histogram of the BNC T-connector image of Fig. 2.6.

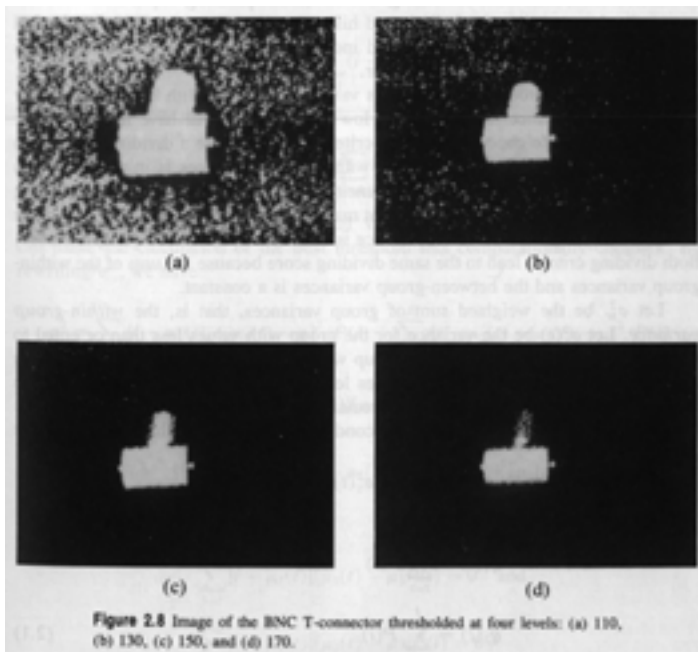


Figure 2.8 Image of the BNC T-connector thresholded at four levels: (a) 110, (b) 130, (c) 150, and (d) 170.

No se distinguen fondo y objeto, por lo que la binarización o bien introduce fondo como objeto o viceversa.

Cálculo del umbral óptimo mediante clustering the minimo error

$$p(z) = P_1 p_1(z) + P_2 p_2(z)$$

$$p(z) = \frac{P_1}{\sqrt{2\pi} \sigma_1} \exp\left[-\frac{(z - \mu_1)^2}{2\sigma_1^2}\right] + \frac{P_2}{\sqrt{2\pi} \sigma_2} \exp\left[-\frac{(z - \mu_2)^2}{2\sigma_2^2}\right]$$

$$P_1 + P_2 = 1$$

Errores de clasificación objeto/fondo en función de T.

$$E_1(T) = \int_{-\infty}^T p_2(z) dz, \quad E_2(T) = \int_T^{\infty} p_1(z) dz, \quad E(T) = P_2 E_1(T) + P_1 E_2(T).$$

Minimización del error nos da: $P_1 p_1(T) = P_2 p_2(T).$

$$AT^2 + BT + C = 0$$

$$A = \sigma_1^2 - \sigma_2^2$$

$$B = 2(\mu_1 \sigma_2^2 - \mu_2 \sigma_1^2)$$

$$C = \sigma_1^2 \mu_2^2 - \sigma_2^2 \mu_1^2 + 2\sigma_1^2 \sigma_2^2 \ln(\sigma_2 P_1 / \sigma_1 P_2).$$

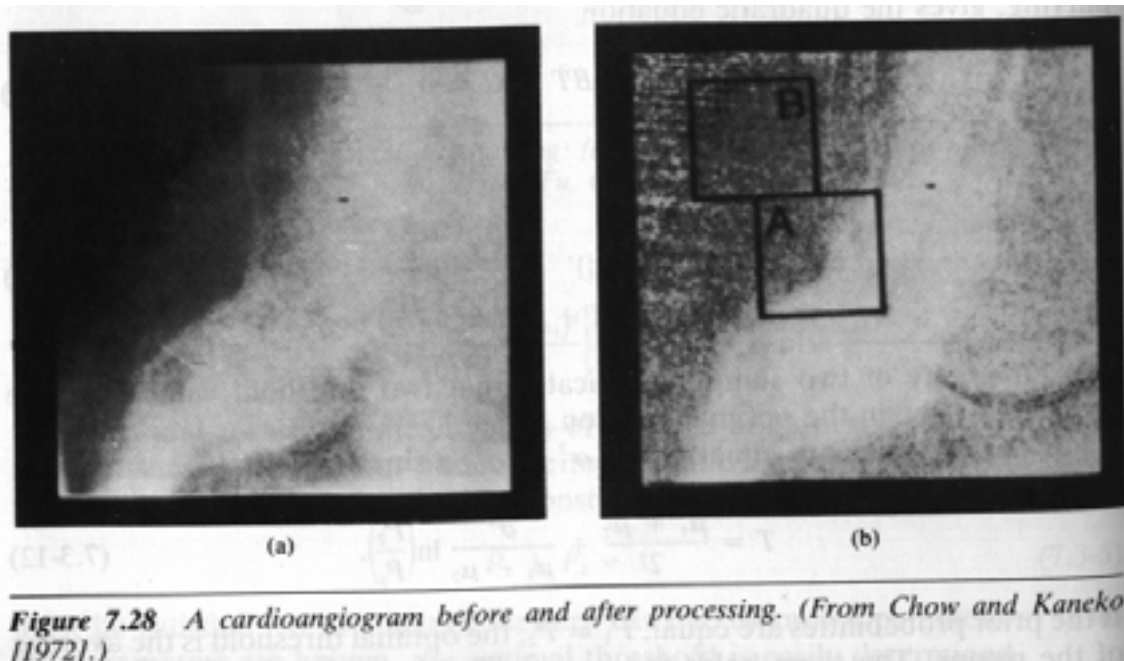
Ecuaciones para el umbral de minimo error de clasificación.

$$T = \frac{\mu_1 + \mu_2}{2} + \frac{\sigma^2}{\mu_1 - \mu_2} \ln\left(\frac{P_2}{P_1}\right), \quad \text{cuando} \quad \sigma^2 = \sigma_1^2 = \sigma_2^2,$$



La estimación de los parámetros de la ddp mezcla se puede hacer minimizando el error.

$$e_{ms} = \frac{1}{n} \sum_{i=1}^n [p(z_i) - h(z_i)]^2$$

Ejemplo de binarización local.



$$f(x, y) = \begin{cases} 1 & \text{if } f(x, y) \geq T_{xy} \\ 0 & \text{otherwise} \end{cases}$$



La imagen se parte en bloques con solapamiento. Para cada bloque se calcula el histograma, si es bimodal se le asigna un umbral. Los bloques sin umbral lo adquieren por interpolación.

Método de mínima varianza intragrupo (Otsu), extraído de Computer & Robot Vision, Haralick & Shapiro

Trata de minimizar en función de t

$$\sigma_W^2(t) = q_1(t) \sigma_1^2(t) + q_2(t) \sigma_2^2(t)$$

$$q_1(t) = \sum_{i=1}^t P(i)$$

$$q_2(t) = \sum_{i=t+1}^l P(i)$$

$$\mu_1(t) = \sum_{i=1}^t i P(i)/q_1(t)$$

$$\mu_2(t) = \sum_{i=t+1}^l i P(i)/q_2(t)$$

$$\sigma_1^2(t) = \sum_{i=1}^t [i - \mu_1(t)]^2 P(i)/q_1(t)$$

$$\sigma_2^2(t) = \sum_{i=t+1}^l [i - \mu_2(t)]^2 P(i)/q_2(t)$$

$$\sigma^2 = \sum_{i=1}^l (i - \mu)^2 P(i)$$

$$\mu = \sum_{i=1}^l i P(i)$$

Dado que el numero de valores que puede tomar el umbral es pequeño se puede realizar la exploración exhaustiva para determinar el umbral que minimiza la varianza intragrupo.




Figure 2.9 Binary image produced by thresholding the T-connector image of Fig. 2.6 with the Otsu threshold.